

Taller PCA

Estudiantes

Lenin Enrique García Caraballo

David Orlando Riaño Morales

Docente

Alexander Pérez Ruiz

Escuela Colombiana de Ingeniería Julio Garavito

Métodos computacionales en ingeniería – MCEI

2026-2

7 de noviembre de 2026

1 Solución del problema

1.1 Código en Octave

A continuación se presenta el código desarrollado paso a paso para el cálculo y proyección de las componentes principales.

```
% 1. Definir la matriz X (10x3)
X = [48, 5.1, 2.1;
     50, 5.3, 2.4;
     51, 5.4, 2.5;
     53, 5.7, 2.8;
     55, 5.8, 3.0;
     56, 6.0, 3.1;
     58, 6.2, 3.5;
     60, 6.3, 3.6;
     61, 6.5, 3.8;
     63, 6.7, 4.0];

N = size(X, 1); % Se obtiene la cantidad de muestras en la matriz de
    datos (debe haber 10)
% Media y desviación estándar, por defecto normaliza con N-1 para
    aplicar la corrección de Bessel
medias = mean(X); % Saca la media para cada variable de la matriz
desv_est = std(X); % Saca la desvición estandar de cada variable

% Se obtiene la matriz de estandarización Z
Z = (X - medias) ./ desv_est;
disp("Media para T, I y V:"), disp(medias);
disp("Desviación estandar para T, I y V:"), disp(desv_est);
disp("Matriz Z:"), disp(Z);

% Se saca la matriz de covarianza usando la ecuacion (Z^T * Z) / (N-1)
S = (Z' * Z) / (N - 1);
disp("Matriz de covarianza S:"), disp(S);

% Se calculan los autovectores y los autovalores usando
[EV, ED] = eig(S);


% Se extrae la diagonal de ED como vector y ordenar de forma descendente
[autovalores, idx] = sort(diag(ED), 'descend');

% Se reordenan las columnas de la matriz de autovectores EV
autovectores = EV(:, idx);
disp("Autovalores:"), disp(autovalores')
disp("Autovectores (columnas PC1, PC2, PC3):"), disp(autovectores)

% Verificación: Suma de autovalores vs Traza de S
disp(["Suma de autovalores: ", num2str(sum(autovalores))]);
disp(["Traza de S: ", num2str(trace(S))]);

% Ahora se calcula la varianza explicada individual y acumulada
var_explicada = (autovalores / sum(autovalores)) * 100;
var_acumulada = cumsum(var_explicada);

disp("Varianza explicada (%):"), disp(var_explicada');
disp("Varianza acumulada (%):"), disp(var_acumulada');

```

```
51
52 % Se seleccionan los primeros 2 autovectores (3x2) mayores
53 W = autovectores(:, 1:2);
54
55 % Se realiza la proyección: los datos de Z(10x3) * W(3x2) -> Proyeccion
       (10x2)
56 proyeccion = Z * W;
57
58 % Graficar e identificar cada muestra
59 figure;
60 scatter(proyeccion(:, 1), proyeccion(:, 2), 'filled');
61 hold on;
62
63 for i = 1:N
64     text(proyeccion(i, 1) + 0.04, proyeccion(i, 2) + 0.004, sprintf('M%d
       ', i), 'FontSize', 10);
65 end
66
67 line(xlim, [0 0], 'Color', 'k', 'LineStyle', '--');
68 line([0 0], ylim, 'Color', 'k', 'LineStyle', '--');
69 xlabel(sprintf('PC1 (%.2f%% varianza)', var_explicada(1)));
70 ylabel(sprintf('PC2 (%.2f%% varianza)', var_explicada(2)));
71 title('Proyeccion de observaciones en el plano PC1 - PC2');
72 grid on;
73 hold off;
```

Listing 1: Script de Análisis de Componentes Principales

1.2 Resultados de las actividades

1.2.1. Actividad 1: Matriz X, media, desviación estandar y matriz de estandarización Z

En el código se define la matriz $\mathbf{X}$ que describe la siguiente tabla con 10 muestras (cada una correspondiente a una ventana de operación), tomadas por 3 indicadores de un motor eléctrico (temperatura, corriente eléctrica y velocidad):

Muestra	T (°C)	I (A)	V (mm/s)
1	48	5.1	2.1
2	50	5.3	2.4
3	51	5.4	2.5
4	53	5.7	2.8
5	55	5.8	3.0
6	56	6.0	3.1
7	58	6.2	3.5
8	60	6.3	3.6
9	61	6.5	3.8
10	63	6.7	4.0

Cuadro 1: Indicadores registrados del motor eléctrico durante diez ventanas de operación.

En el código se calcula la media y la desviación estandar para cada variable. Sus ecuaciones son respectivamente:

$$\mu_j = \frac{1}{N}\sum_{i=1}^{N} X_{ij} \tag{1}$$

$$\sigma_j = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(X_{ij} - \mu_j)^2} \tag{2}$$

Donde N es la cantidad de columnas de **X**.
Posteriormente se hace el cálculo de la matriz **Z**, cuyos elementos son los datos de **X** centrados en el cero del espacio tridimensional de los mismos, además de que están escalados. En resumen, la matriz **Z** contiene a los datos de **X** ya estandarizados. La ecuación de **Z** es:

$$Z_{ij} = \frac{X_{ij} - \mu_j}{\sigma_j} \tag{3}$$

Donde:

- X_{ij}: Valor original de la observación i en la variable j.
- μ_j: Media aritmética de la variable j.
- σ_j: Desviación estándar de la variable j.

El código arrojó los siguientes resultados:

```
Media para T, I y V:
   55.5000    5.9000    3.0800
Desviación estandar para T, I y V:
   5.0166   0.5333   0.6374
Matriz Z:
  -1.495025  -1.500000  -1.537603
  -1.096352  -1.125000  -1.066908
  -0.897015  -0.937500  -0.910010
  -0.498342  -0.375000  -0.439315
  -0.099668  -0.187500  -0.125519
   0.099668   0.187500   0.031380
   0.498342   0.562500   0.658973
   0.897015   0.750000   0.815871
   1.096352   1.125000   1.129668
   1.495025   1.500000   1.443464
```

Figura 1: Medias, desviaciones estandar y matriz Z

1.2.2. Actividad 2: Matriz de covarianza S

Para calcular la matriz de covarianza se usó la siguiente ecuación:

$$S = \frac{1}{N-1} Z^T Z \tag{4}$$

Esto evita que se tengan que calcular a mano las covarianzas entre las variables para formar varios de los elementos de **S**. La matriz resultante fue la siguiente:

```
Matriz de covarianza S:
   1.0000   0.9967   0.9973
   0.9967   1.0000   0.9970
   0.9973   0.9970   1.0000
```

Figura 2: Matriz de convarianza **S**

Las covarianzas (datos que no estan en la diagonal principal de **S**) son todas positivas y cercanas a 1. Por lo tanto, debido a que todas esas covarianzas tomaron valores entre 0,9967 y 0,9973, se puede afirmar que si una variable aumenta, las otras dos también van a aumentar.

1.2.3. Actividad 3: Autovalores y Autovectores

Para calcular los autovalores y autovectores en Octave se indica que cree una matriz **EV** para guardar los autovectores, y una matriz **ED** para los autovalores. El cálculo lo realiza la función **eig(S)** usando la matriz de covarianza **S**.
Luego, con **diag(ED)** toma la matriz cuadrada ED y extrae únicamente los números de la diagonal principal, convirtiéndolos en un vector simple. Y para los autovalores y ordenarlos, se usa **[autovalores, idx] = sort(diag(ED), 'descend');**.
Los autovectores y autovalores ordenados fueron los siguientes:

```
Autovalores:
   2.9940e+00   3.3881e-03   2.6223e-03
Autovectores (columnas PC1, PC2, PC3):
   0.5774   0.5487   0.6046
   0.5773  -0.7980   0.1730
   0.5774   0.2492  -0.7775
```

Figura 3: Autovalores y autovectores

Al sumar los tres autovalores se obtiene un valor de 3, y al sumar la traza de la matriz de covarianza **S** también se obtiene 3:

```
Suma de autovalores: 3
Traza de S: 3
```

Figura 4: Suma de los autovalores y cálculo de la traza de **S**

Puede observarse que ambos valores coinciden, lo que significa que no se ha perdido ni creado ninguna información (varianza) durante la transformación.

1.2.4. Actividad 4: Calculo de la varianza explicada individual y acumulada.

```
Varianza explicada (%):
   9.9800e+01   1.1294e-01   8.7410e-02
Varianza acumulada (%):
    99.800    99.913   100.000
```

Figura 5: Varianza explicada individual y acumulada

Según los resultados obtenidos, la primera componente principal (PC1) representa el 99.800 % de la información de los datos originales. Por otro lado, la segunda componente (PC2) aporta un 0.113 %, y la tercera componente (PC3) un 0.087 %. Esto significa que la mayor parte de la información se encuentra concentrada en la primera componente.

En cuanto a la varianza acumulada, se observa que utilizando únicamente la primera componente se conserva el 99.800 % de la información. Si se utilizan las dos primeras componentes (PC1 y PC2), este porcentaje aumenta al 99.913 %. Con dos componentes principales es posible representar prácticamente toda la información de las tres variables originales, reduciendo así la cantidad de dimensiones sin perder información significativa.

1.2.5. Actividad 5: Proyección sobre plano PC1–PC2.

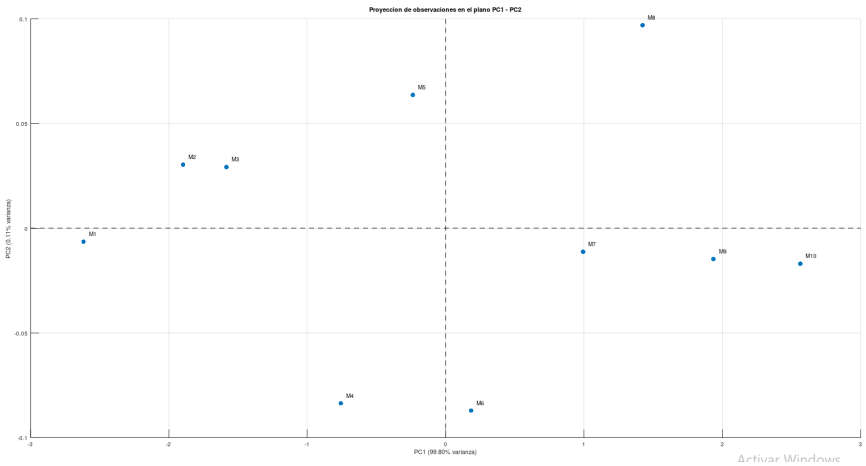


Figura 6: Gráfica de las 10 muestras redimensionadas

La gráfica muestra cómo se distribuyen las diez muestras del motor al representarlas utilizando las dos primeras componentes principales (PC1 y PC2). La mayor parte de la información se concentra en PC1, que explica el 99.80 % de la variabilidad, mientras que PC2 representa únicamente el 0.11 %. Por esta razón, las muestras presentan una distribución principalmente horizontal, ubicándose desde M1, en el extremo izquierdo, hasta M10, en el extremo derecho. Esto indica que PC1 recoge principalmente el comportamiento general de las tres variables originales del motor.

Al observar las muestras más cercanas, se destaca que M2 y M3 presentan posiciones muy similares en la gráfica, lo que indica que sus mediciones tuvieron comportamientos parecidos. Además, M7, M9 y M10 siguen una distribución progresiva sobre el eje horizontal, mostrando una tendencia similar en sus mediciones.

Las muestras más alejadas son M1 y M10, ya que se encuentran en extremos opuestos de PC1. Esto indica que representan condiciones de operación diferentes: M1 corresponde a uno de los estados de menor exigencia del motor, mientras que M10 representa uno de los estados de mayor exigencia.

1.2.6. Actividad 6: Recomiende conservar dos componentes o mantener las tres variables. Sustente la decisión con resultados y con el propósito de monitoreo.

2 Preguntas de reflexión

2.1 ¿Qué problema aparecería si se aplica PCA directamente a las variables originales sin estandarizarlas, teniendo unidades °C, A y mm/s?

Debido a que la temperatura (T) toma valores muy grandes y tiene varianzas muy grandes (48 a 63 °C, con una varianza original de $\approx 25{,}17$), y la corriente (I) y la vibración RMS (V) tienen muy poca variación (varianzas de $\approx 0{,}296$ y $\approx 0{,}415$ respectivamente), si no se estandariza, la temperatura dominaría el componente PC1 por tener números mucho más altos.
Si se calcula la matriz de covarianza con datos crudos, las variables con magnitudes más grandes absorberán casi por completo los primeros componentes principales, haciendo invisible la verdadera correlación física del sistema. Es por esto que se necesita calcular la matriz **Z**, debido a

que precondiciona el espacio para que todas las variables tengan una varianza unitaria y el PCA identifique la verdadera estructura de correlación sin sesgos de escala.

2.2 Si PC1 y PC2 explican un porcentaje alto de la varianza, ¿podría perderse información útil para detectar una falla incipiente? Explique.

Si se confia solo en los porcentajes altos, se corre el riesgo de perder la información clave para hacer un diagnóstico predictivo.
Es verdad que PC1 y PC2 retienen el 99,91 % de la varianza, pero eso solo representa la operación normal del motor (cuando le exigimos más carga, las tres variables suben al tiempo). El problema es que una falla incipiente, como el desgaste inicial de un rodamiento, va a hacer que la vibración suba de forma aislada, sin afectar todavía la corriente o la temperatura.
Ese cambio rompe la colinealidad normal de los sensores y, matemáticamente, ese comportamiento "desacoplado"no se va a ver ni en PC1 ni en PC2; se va a aislar en PC3 (el subespacio residual). Si descartamos PC3 en un sistema de monitoreo solo porque explica apenas el 0,08 % de la varianza total, estaríamos botando a la basura precisamente la señal de anomalía que nos avisa de la falla antes de que sea crítica.